

阮紹銘

AI 工程師 · 模型壓縮與部署

聯絡方式

- bend06b@gmail.com
- +886 988 106 253
- 台南, 台灣
- github.com/d-ben-b
- LinkedIn
- d-ben-b.github.io

技能

程式語言

- Python
- JavaScript
- SQL
- C / C++

機器學習 / 深度學習

- PyTorch
- Hugging Face
- timm
- OpenCV
- scikit-learn

模型壓縮

- Pruning (N:M)
- Quantization (INT8)
- Distillation
- ONNX / TensorRT

視覺 · LLM · RL

- DeepLabV3
- UNet++
- YOLO
- RAG / FAISS
- Gemma · Llama
- PPO / DQN

資料 · 全端 · 環境

- pandas
- LightGBM
- Django
- Vue.js
- Docker
- Git

學歷

國立成功大學 (NCKU)

2025 - 2027

電機工程碩士 · 資訊工程組

- 研究方向：高效率 AI 與模型壓縮

國立成功大學 (NCKU)

2021 - 2025

電機工程學士

- GPA 4.04 / 4.3 — 畢業班排名前 20%
- 書卷獎 (學業優異)
- 半導體專長微學程

重點修課

- 深度學習與應用 (A+)
- 影像處理、電腦視覺與深度學習 (A+)
- AI 晶片設計與應用
- 系統程式 (A+)
- 機率與統計 (A+)
- 線性代數 (A+)

重點論文 (高效率 AI)

- MobileNets (深度可分離卷積)
- Rethinking the Value of Network Pruning
- 物件偵測知識蒸餾 (NeurIPS '17)

簡介

國立成功大學電機工程研究所 (資訊工程組) 碩士生，專精高效率 AI——把深度學習模型壓縮到可實際部署的規模。熟悉完整壓縮流程 (通道 / token 剪枝、INT8 量化、知識蒸餾)，並具備電腦視覺、RAG / LLM 與 Vue / Django 全端開發經驗。能端到端從訓練、量測到邊緣部署，亦多次於黑客松主導技術開發 (最佳人氣獎、多場決賽入圍)。

專案經歷

模型壓縮全流程 — 剪枝 · 量化 · 蒸餾

2024 - 2025

高效率 AI 研究 技術報告 ↗

PyTorch · Network Slimming · PTQ / QAT · timm · ONNX

- 以 Network Slimming (BN-γ L1 稀疏) 對 ResNet-50 通道剪枝，參數量自 23.5M 降至 3.65M (−84%)；微調後 top-1 準確率回復至 91.8% (幾乎無損)。
- 以 PTQ 與 QAT 將 CNN 量化為 INT8，推論延遲自 **10.6ms** 降至 **3.5ms** (3.06× 加速)，準確率維持 95.38%。
- 加入知識蒸餾 (ResNet-50 → ResNet-18，溫度調控 soft logits) 與注意力導向的 ViT token 剪枝 (EViT，keep-rate 0.7)，構成完整的「剪枝 → 量化 → 蒸餾」工具箱。

邊緣 AI 長照陪伴機器人

2025

系統設計

Jetson Nano · TensorRT / TFLite · INT8 · ONNX

- 設計可於 Jetson Nano / Raspberry Pi 離線運行的語音互動機器人：Distil-Whisper 語音辨識 + 量化小型 LLM (LLaMA-3-mini / Phi-3) + YOLOv8-Nano 追蹤，訂定延遲 ≤1.2s、模型 ≤400MB、功耗 ≤15W 的效率目標。
- 以 INT8 量化與 2:4 結構化剪枝整合 ASR + LLM + CV 多模組，並在延遲 / 體積 / 功耗預算間進行系統層級取舍。

自駕高速公路決策：PPO vs. DQN 架構消融

2025

強化學習研究

PyTorch · PPO · Double DQN · Self-Attention · highway-env

- 從零實作 PPO 與 Double DQN (GAE、clipped surrogate、replay buffer、target network)，於 highway-env 上訓練，並與 Stable-Baselines3 交叉驗證。
- 以參數對齊的 Self-Attention vs. MLP 消融 (n=5 seeds) 得出關鍵發現：三者 episodic return 差距 ≤5.7%，但部署碰撞率相差約 7× (DQN 11.3% vs. PPO 60–80%)，凸顯單看 return 對安全關鍵控制具誤導性。

無人機空拍語意分割

2025

KAGGLE 競賽

PyTorch · DeepLabV3 · UNet++ · ResNet-101

- 建立 16 類無人機語意分割 pipeline，比較 DeepLabV3 與 UNet++；DeepLabV3-ResNet101 以 CE + Dice 混合損失取得 Kaggle public mIoU 0.58。
- 找出並修正 pipeline 的正規化 / 尺寸對齊問題，分數自 mIoU 0.26 回升至 0.58。

臉部表情影像分類

2024

電腦視覺

PyTorch · EfficientNet-B0 · ResNet18 · Transfer Learning

- 於七類臉部表情辨識 (約 4.5 萬張) 比較 ResNet18、EfficientNet-B0 與自建 CNN；EfficientNet-B0 達約 79.1% 驗證準確率，並以混淆矩陣進行錯誤分析。

RAG 講義問答系統

2025

LLM / NLP

FAISS · SentenceTransformers · Gemma-3 · Llama-3.2 / Ollama

- 為課程講義建立 RAG 問答系統 (PPTX → FAISS 向量庫)；導入檢索後 BLEU 自 0.028 升至 0.110 (約 4×)，ROUGE-L 0.19 → 0.33，BERTScore 0.848 → 0.888。
- 比較 Gemma-3-1B (HF) 與 Llama-3.2 (Ollama) 兩後端，並以案例證明 RAG 能對齊預訓練未涵蓋的在地化語意。

Google Cloud — 生成式 AI 與雲端基礎

Vertex AI · LLM · Prompt Design · 2025

DeepLearning.AI — 深度學習 (吳恩達)

神經網路 · DNN 調校 · ML 專案 · 2023

機器學習基礎 — 華盛頓大學 2025

Python 互動程式設計 I-II — Rice 大學

2023

— 語言

英文 TOEIC 835 (聽 455 / 讀 380)

中文 母語

食物辨識健康理財平台

SPARKFUL AI 黑客松 · 決賽入圍 Demo ↗

Vue.js · Django · YOLOv11n · REST API

- 於 200+ 隊中入圍決賽；獨力負責端到端開發，並在 UECFOOD256 (256 類食物) 上重新訓練 YOLOv11n 作為辨識核心。
- 以 Vue + Django (MVT) 透過 REST API 串接，將辨識結果接入健康評分與金融激勵機制。

公衛資訊整合平台

台南數位治理黑客松 · 最佳人氣獎

Vue.js · Flask · MySQL

- 獲 2024 台南數位城市治理黑客松「最佳人氣獎」(數位發展部 / 台南市)；為衛生局把易出錯的共用 Excel 流程改造為具權限控管的網頁平台。
- 以 Vue + Flask 實作 RBAC、輸入驗證、帶時間戳的版本紀錄與任務追蹤，支援跨部門協作。

可疑帳戶 (詐欺) 偵測

AI CUP 2025 · 玉山

Python · LightGBM · PU Learning · pandas

- 將僅有正樣本 (警示帳戶) 的詐欺偵測建模為 PU Learning (Elkanoto) + LightGBM 問題；名次 261 / 790。
- 建構帳戶雙向 (from/to) 交易特徵，並處理高度不平衡資料中的全零欄位與標籤稀疏問題。

量化交易策略 (FinTech)

演算法 / 金融

Python · NumPy · Dynamic Programming

- 實作財務內部報酬率 (IRR) 求解與多股交易策略最佳化，並以動態規劃在手續費與冷卻期約束下求最大化報酬。

— 獲獎與競賽

- 最佳人氣獎 — 2024 台南數位城市治理黑客松 (數位發展部 / 台南市)
- 決賽入圍 (200+ 隊) — 2025 Sparkful「Hack to the Top」AI 黑客松
- AI CUP 2025 · 玉山人工智慧公開挑戰賽 (警示帳戶偵測) — 261 / 790
- 決賽入圍 — 2025 花蓮 HSH 黑客松
- 書卷獎 (學業優異) — 成功大學電機資訊學院